NLP лекция 2

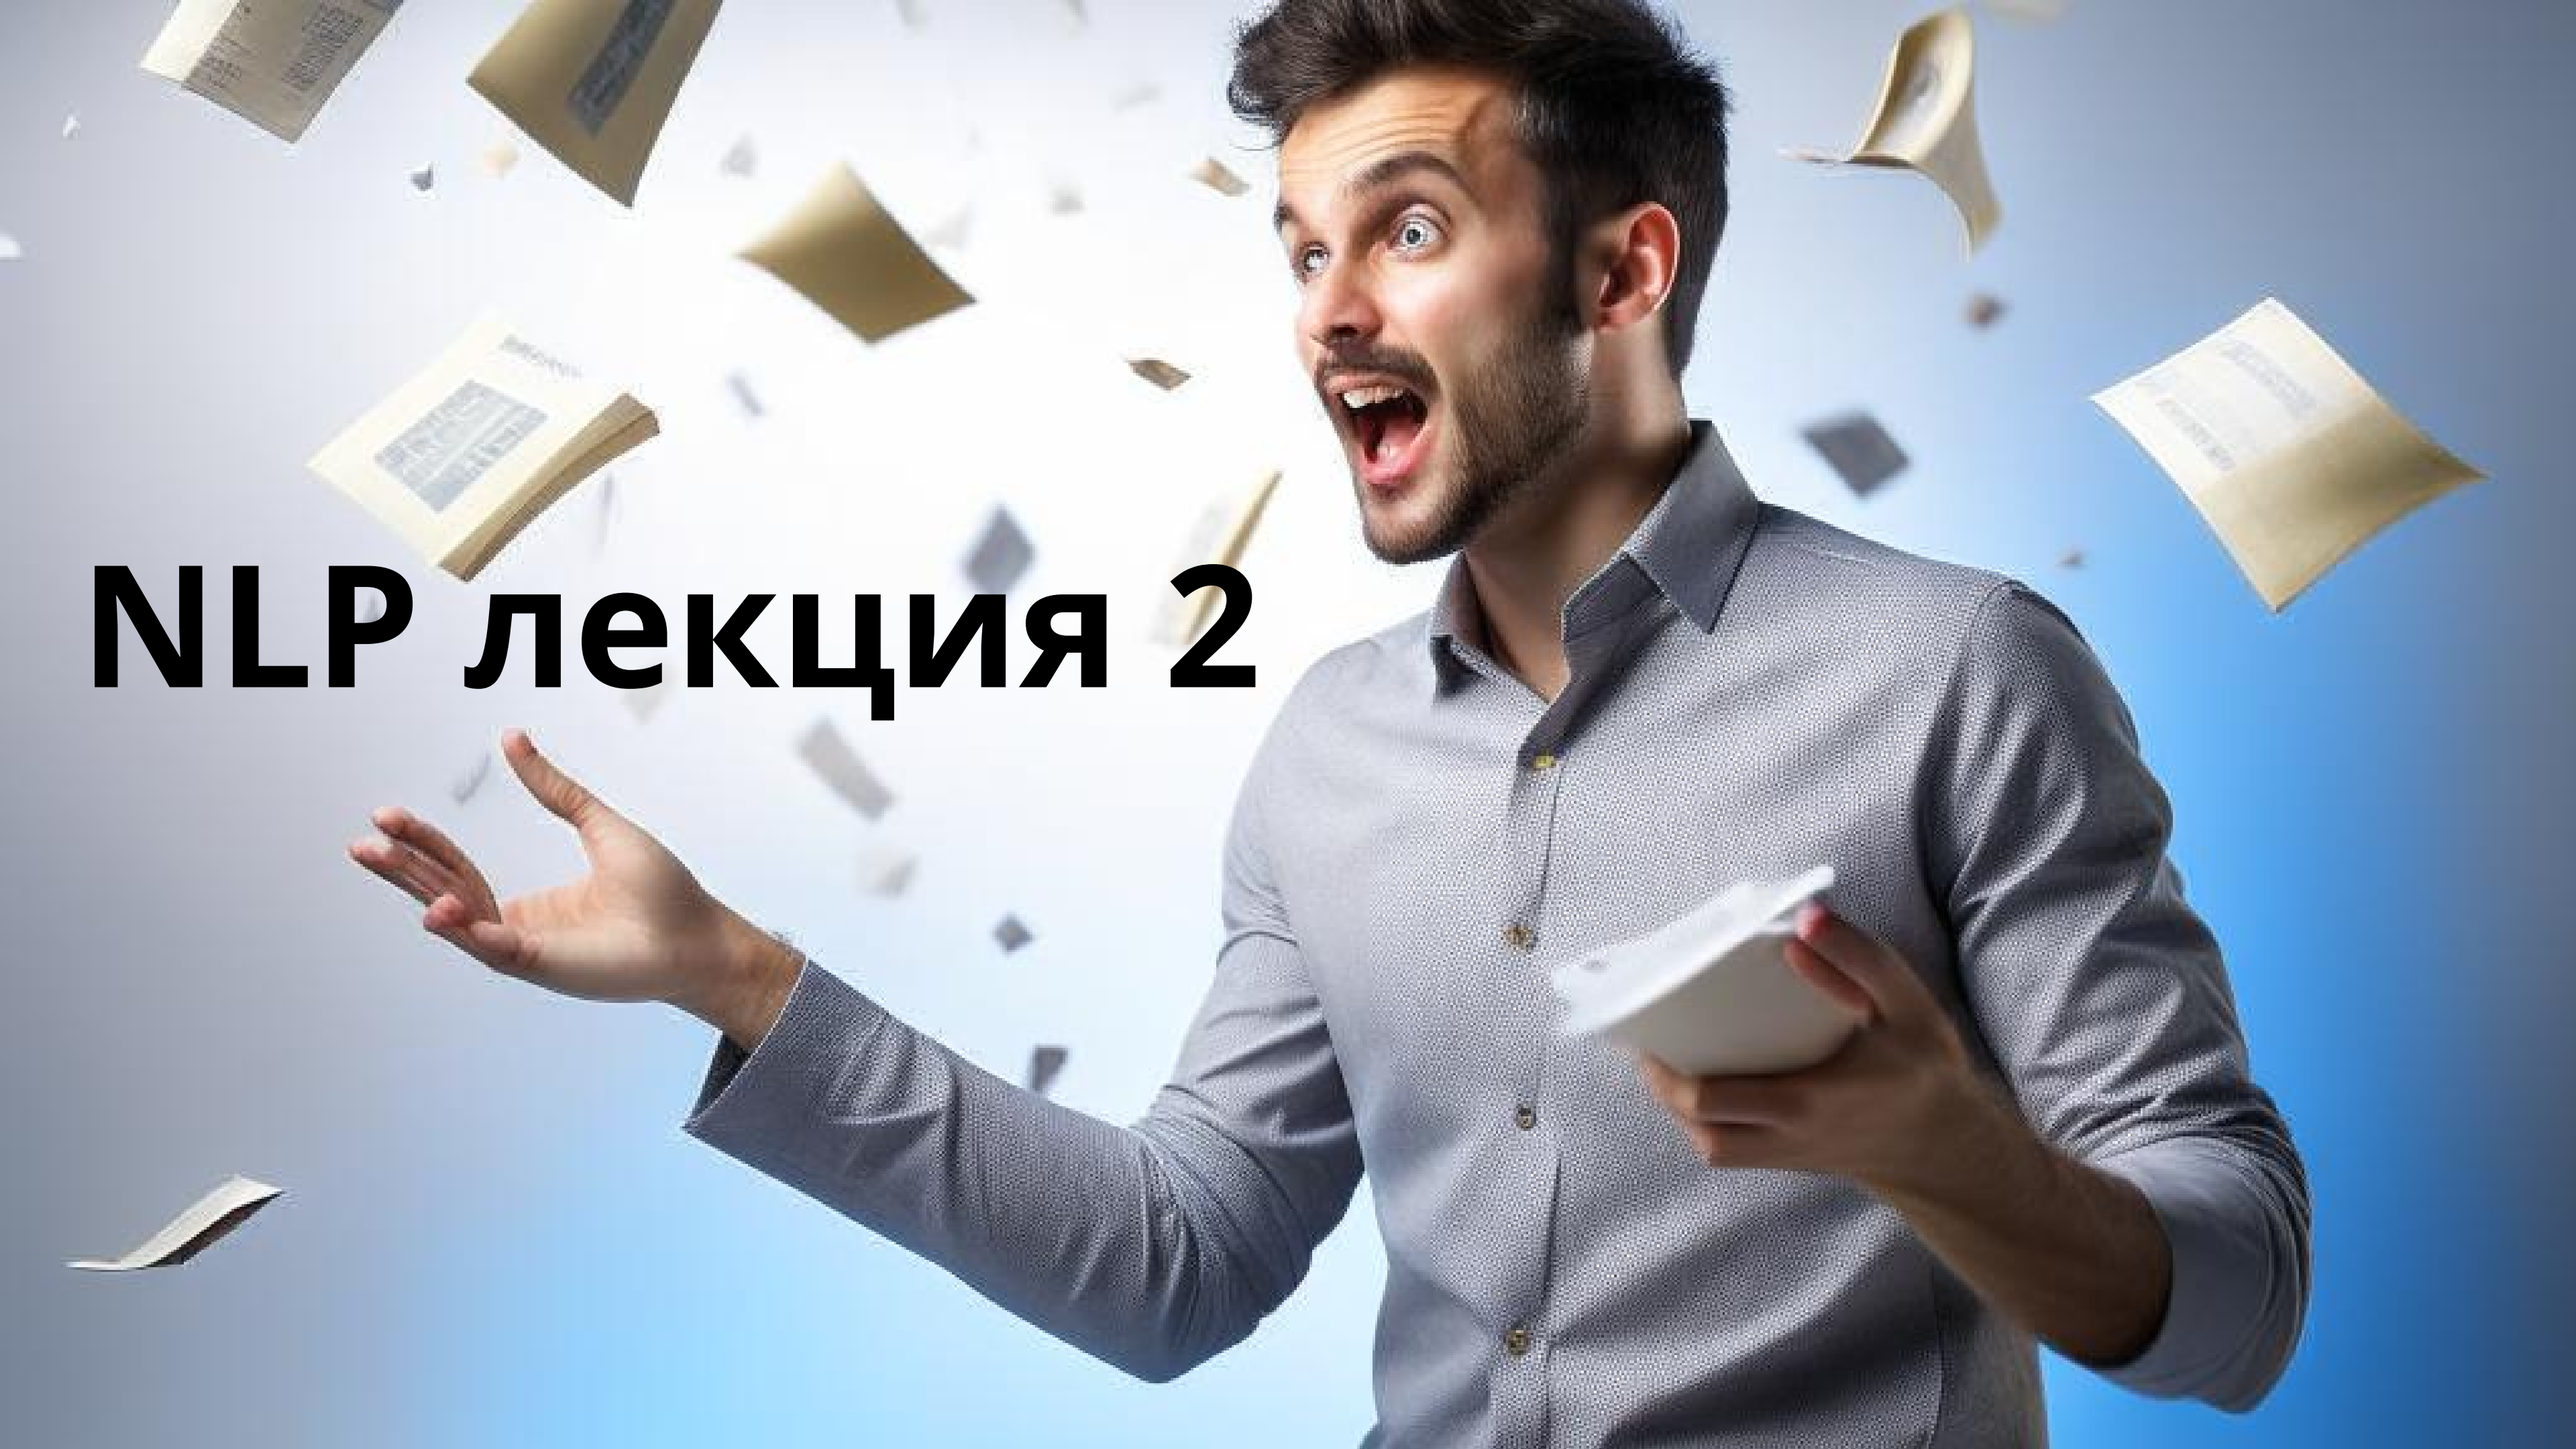

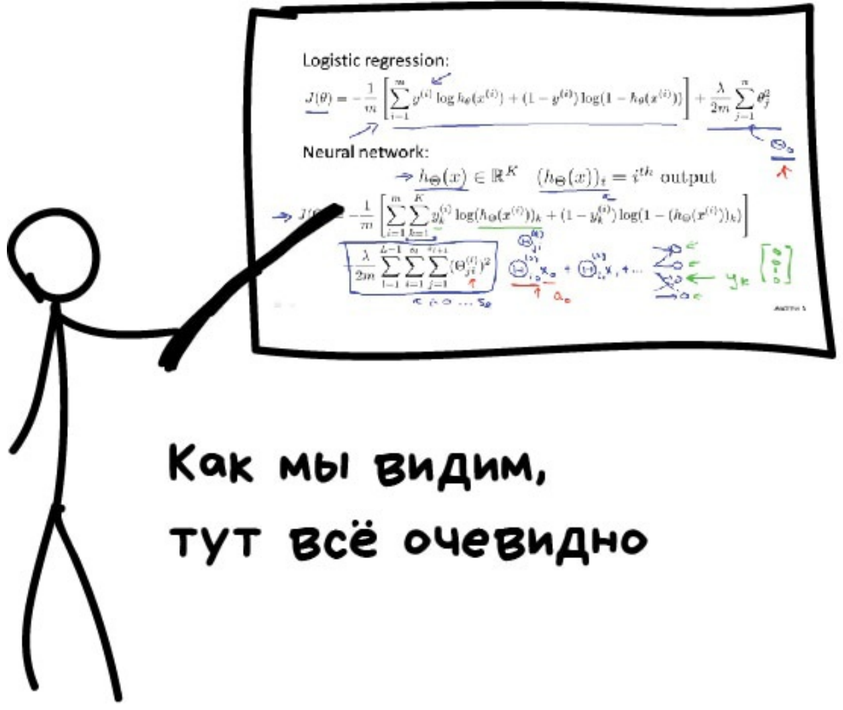

Как мы видим,
тут всё очевидно

Программисты программируют!
Датасаенс!
Профессия будущего!
Буквально через пять лет...
Экспоненциально!!!
УМНЫЕ РОБОТЫ!
А-А-А-А-А-А-А-А-А-А-ааа!!!!!!!

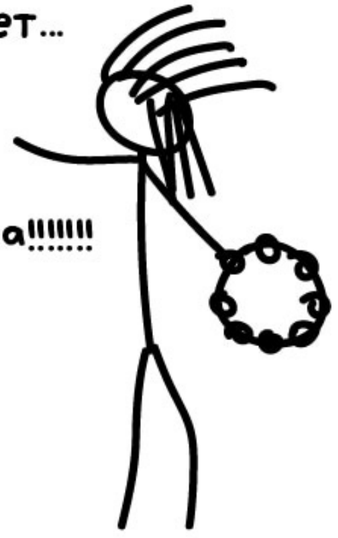

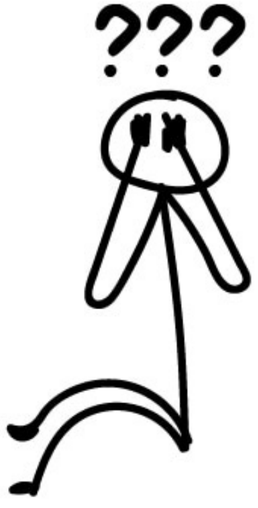

Есть два типа статей про машинное обучение

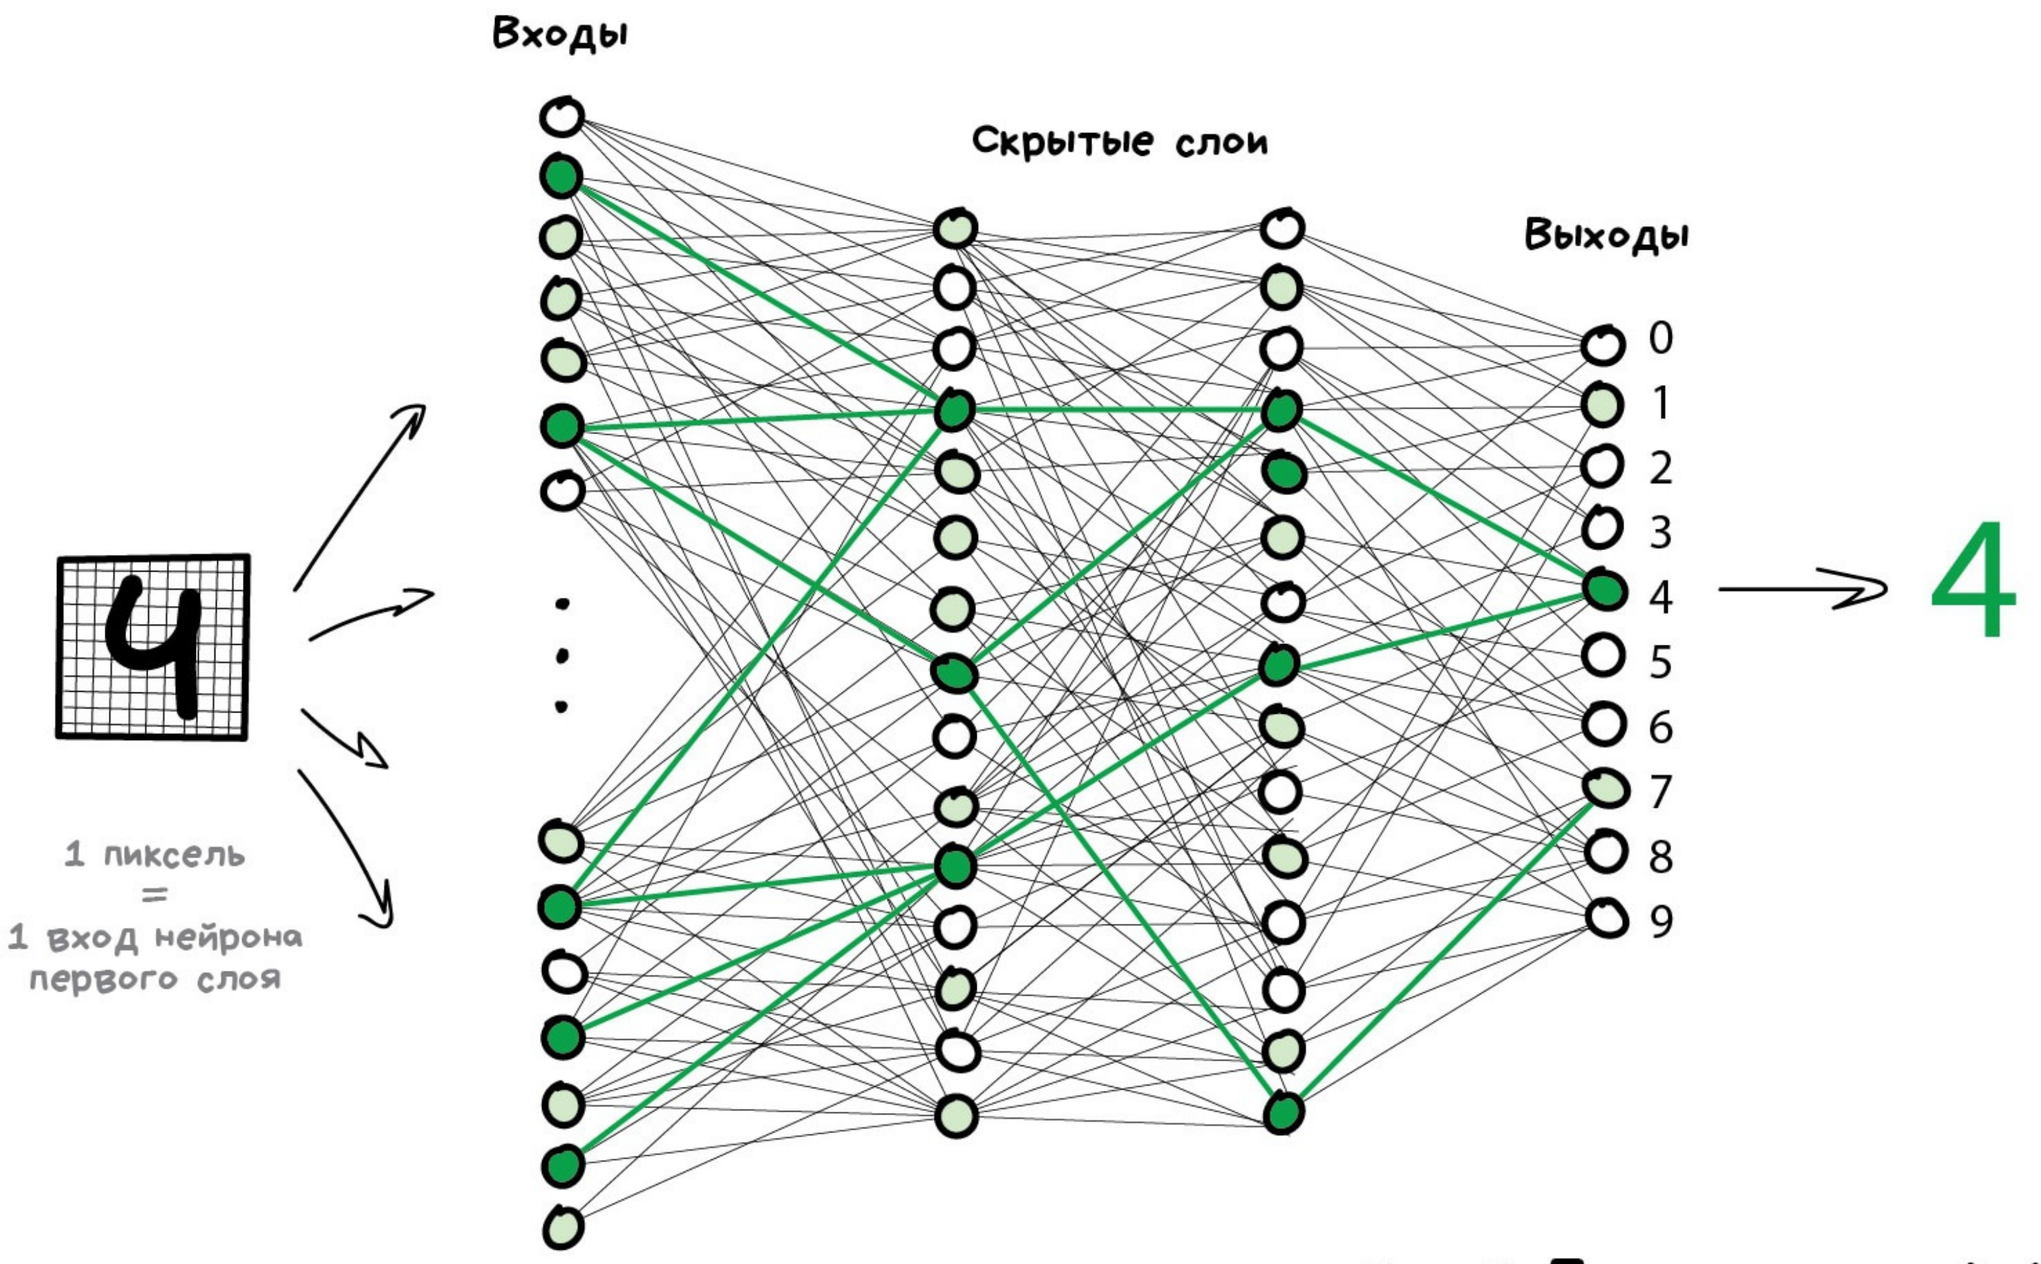

Многослойный Перцептрон (MLP)

Основные виды машинного обучения

Простые данные
Понятные признаки

Классическое обучение

Данных нет,
но есть среда,
с которой можно
взаимодействовать

Обучение с подкреплением

Когда качество
правда проблема

Ансамбли

Вечные конкуренты

Сложные данные
Непонятно где
признаки
Есть вера в чудо

Нейросети и глубокое обучение

Подготовка текста: токенизация, лемматизация, мешки слов

Токенизация

Токенизация (англ. tokenization) — разбиение текста на токены: отдельные фразы, слова, символы.

Как правило, токенизация - один из этапов, уже “зашитых” в лемматизацию

Лемматизация

Лемматизация (англ. lemmatization) — приведение слова к начальной форме — лемме.

Функция лемматизации русского текста есть в библиотеках:

- **pymorphy2**
- **UDPipe**
- **pymystem3**

Для английского текста, например, в **WordNetLemmatizer**

(Посмотрим пример использования pymystem в google colab)

Регулярные выражения

Регулярные выражения (англ. regular expressions) **-** это инструмент для поиска слова или числа по шаблону (англ. pattern). Он определяет, из каких частей состоит строка и какие в них символы.

Для работы с регулярными выражениями в Python есть встроенный модуль **re**

(Посмотрим пример использования re в google colab)

Мешок слов

Преобразовать слова в векторы поможет модель «**мешок слов**» (англ. bag of words). Она преобразует текст в вектор, не учитывая порядок слов. Отсюда и название — «мешок».

Чтобы преобразовать корпус текстов в мешок слов, обратимся к классу **CountVectorizer()** (англ. count vectorizer, «счётчик слов для создания векторов»). Он находится в модуле sklearn.feature_extraction.text (англ. «построение признаков текста»).

(Посмотрим пример в google colab)

Стоп-слова

Чтобы почистить мешок слов, найдём **стоп-слова**, то есть слова без смысловой нагрузки.

Их много, и для каждого языка — свои.

За это отвечает пакет **stopwords**, который находится в модуле **nltk.corpus** библиотеки nltk (англ. Natural Language Toolkit, «инструментарий естественного языка»)

(Посмотрим пример в google colab)

NERD
IOSE

PIPELINE NLP

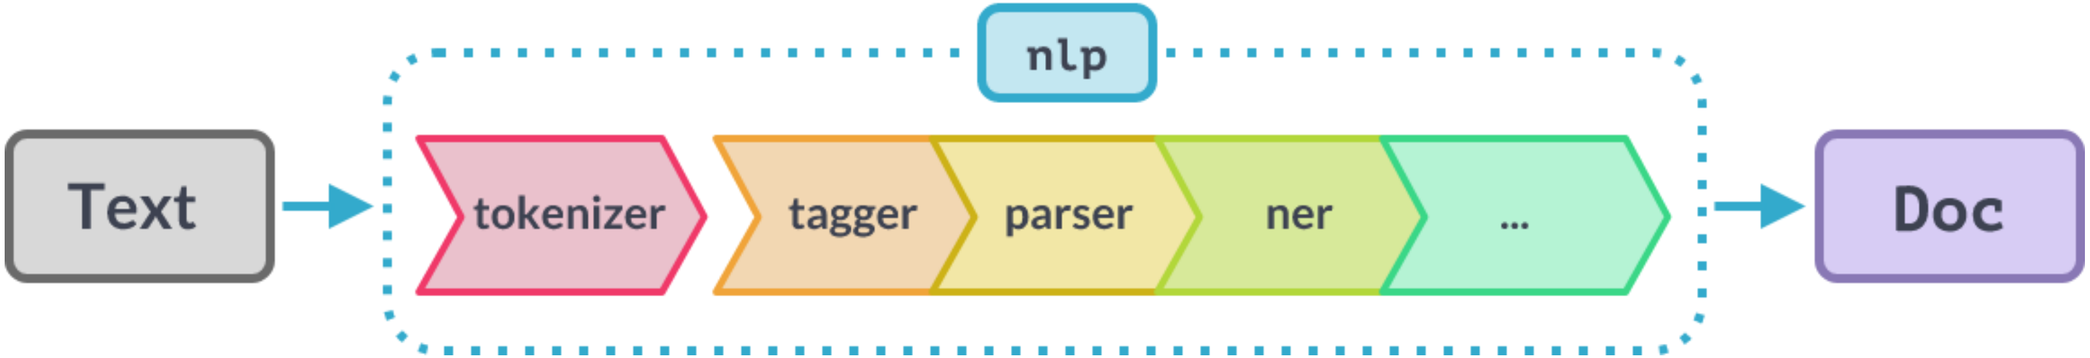

Сегментация - деление текста на предложения

Токенизация - деление предложений на токены, то есть отдельные слова.

Дальше нужно вычислить признаки каждого токена.

Обычные контекстно-независимые признаки – это:

- эмбеддинги (сопоставление слова вектору)
- символьные признаки
- дополнительные признаки, специальные для конкретной задачи или языка

BIOES - СХЕМА

Карл Фридрих Иероним фон Мюнхгаузен родился в Боденвердере

B-PER I-PER I-PER I-PER E-PER OUT OUT S-LOC

B – от слова beginning – первый токен в спане сущности, который состоит из больше чем 1 слова.
I – от словам inside – это то, что находится в середине.
O - out (игнорируем)
E – от слова ending, это последний токен сущности, которая состоит больше чем из 1 элемента.
S – single. Мы добавляем этот префикс, если сущность состоит из одного слова.

12	В	в	PR	PR=	OUT
12	январе	январь	S	S,муж,неод=пр,ед	OUT
12	1995	1995	UNDEF	UNDEF	OUT
12	года	год	S	S,муж,неод=(вин,мн|род,ед|им,мн)	OUT
12	в	в	PR	PR=	OUT
12	Подмосковье	подмосковье	S	S,гео,сред,неод=(пр,ед|вин,ед|им,ед)	S-LOC
12	состоялся	состояться	V	V,сов,нп=прош,ед,изъяв,муж	OUT
12	учредительный	учредительный	A	A=(вин,ед,полн,муж,неод|им,ед,полн,муж)	OUT
12	съезд	съезд	S	S,муж,неод=(вин,ед|им,ед)	OUT
12	Общероссийского	общероссийский	A	A=(вин,ед,полн,муж,од|род,ед,полн,муж|род,ед,полн,сред)	B-ORG
12	общественного	общественный	A	A=(вин,ед,полн,муж,од|род,ед,полн,муж|род,ед,полн,сред)	I-ORG
12	движения	движение	S	S,сред,неод=(вин,мн|род,ед|им,мн)	I-ORG
12	"	"	UNDEF	UNDEF	I-ORG
12	Яблоко	яблоко	S	S,сред,неод=(вин,ед|им,ед)	I-ORG
12	" .	" .	UNDEF	UNDEF	E-ORG

ссылки

https://vas3k.ru/blog/machine_learning/ (MUST READ!)

https://habr.com/ru/company/abbyy/blog/437008/
https://habr.com/ru/company/abbyy/blog/449514/

https://ru.shaip.com/blog/named-entity-recognition-and-its-types/

Студент

Машина может	Машина не может
Предсказывать	Создавать новое
Запоминать	Резко поумнеть
Воспроизводить	Выйти за рамки задачи
Выбирать лучшее	Убить всех людей ?